

An approximate logic neuron model with a dendritic structure

吉君恺

摘要

复现的论文是以生物神经元为灵感，提出了一种基于树枝晶相互作用和树枝晶塑性机制的近似逻辑神经元模型。该模型由四层组成：突触层、树突层、膜层和胞体。ALNM 具有神经元修剪功能，通过在训练过程中筛选无用的突触和不必要的树突，形成特定任务的独特树状拓扑结构。此外，与成熟的枝晶形态相对应，训练好的 ALNM 可以用逻辑电路代替，使用逻辑 NOT、AND 和 OR 运算，具有强大的运算能力，并且可以简单地在硬件上实现，能降低计算复杂度，加快数据集的收敛速度。

关键词：树突；反向传播；剪枝；模式分类；逻辑电路

1 引言

神经生物学的最新进展使修剪的重要性凸显出来，修剪是神经元在神经发生早期阶段选择性地去掉不必要的树突而不导致细胞死亡的过程。在果蝇蘑菇体和树突树杈神经元中分别发现了轴突修剪和树突修剪。基于这些新的生物物理现象，建立一个近似逻辑神经元模型，用于形态学可塑性神经元的计算，得到人工神经中更真实的单神经元计算模型网络，有效地解决了线性不可分问题。

2 相关工作

2.1 剪枝

在网络训练过程中寻求一种评判机制，剔除掉不重要的连接、节点甚至卷积核，达到精简网络结构的目的。很多实验表明卷积层到全连接层存在大量冗余参数，大多是神经元被激活后的输出值区域 0，即使将这些神经元剔除也能够表达出模型特征。

剪枝的好处：训练时间少，随着计算量的减少，网络中连接每次迭代的速度得到提升，网络模型可以更快的收敛到最优解；运行速度快，稀疏化后的网络卷积层数、卷积层中的卷积核个数都更少，更简单更轻便的模型意味着更高效、快速的权重更新；更可行的嵌入式部署，剪枝后的网络在移动设备及其他嵌入式设备上的应用提供了更广泛的可能。

2.2 反向传播

前向传播时将训练集数据输入到神经网络的输入层，经过隐藏层，最后到达输出层并输出结果。由于神经网络的输入结果与输出结果有误差，则计算估计值与实际值之间的误差，并将该误差从输出层向隐藏层反向传播，直至传播到输入层。在反向传播的过程中，根据误差调整各种参数的值；不断迭代上述过程，直至收敛。

3 本文方法

3.1 本文方法概述

搭建 ALNM 模型, ALNM 结构有四层: 突触层、树突层、膜层和细胞体 (如图 1 所示)。根据 ALNM 的结构实现模型的前向传播过程, 然后将误差反向传播算法应用到 ALNM 模型, 推导 ALNM 的反向传播过程, 在此基础上实现模型的反向传播。用基准数据集中 Iris 数据集的来评估 ALNM 的性能, 以解决模式分类问题。评估 ALNM 与标准的 BP 网络模型在同一数据集上的表现, 两者隐藏与输出层传递函数均设置为 Log-sigmoid, 学习率设置为 0.1, 权值数量几乎相等。




图 1: ALNM 结构

3.2 神经元修剪功能实现

(1) 轴突修剪:

对于 Constant 1 连接的轴突输入, 突触层的输出为 1。由于乘法运算, 任意值乘以 1 得到它自己。这意味着突触输入对树突层的结果没有影响; 因此, 我们可以完全忽略这个突触层的输入。

(2) 树突修剪:

一旦轴突输入处于 Constant 0 连接中, 该层的输出为 0, 因为任何值乘以 0 得到 0。乘法运算使整个树突层为 0, 而不管树突层中是否有其他突触信号。由于该树突分支对膜层没有影响, 因此需要删除该分支。

4 复现细节

4.1 与已有开源代码对比

突触层代表神经元树突的突触连接, 这是由接收特定离子的受体实现的。当离子进入受体时, 受体的电位发生变化, 决定它是兴奋突触还是抑制突触。用一个 sigmoid 函数来表示连接状态, Wim 和 qim 为连接参数。当 wim 和 qim 值不同, 6 种情况对应 4 种连接状态: 常 0 连接、常 1 连接、反向连接和常 1 连接, 在图 2 代码中实现了 4 种连接状态。

```

% build synaptic layers 根据w、q值，确定连接情况，直接得出突触层输出的取值
for m=1:M
    for i=1:I
        % Constant 1 connection
        if K(i,m)==2
            Y(i,m,j)=1;
        end
        % Constant 0 connection
        if K(i,m)==0
            Y(i,m,j)=0;
        end
        % Inverse connection
        if K(i,m)==-1
            if input(i,j)<Threshold(i,m)%跟突触层的阈值比较
                Y(i,m,j)=1;
            else
                Y(i,m,j)=0;
            end
        end
        % Direct connection
        if K(i,m)==1
            if input(i,j)<Threshold(i,m)
                Y(i,m,j)=0;
            else
                Y(i,m,j)=1;
            end
        end
    end
end

```

图 2: 突触层

4.2 实验环境搭建

搭建 Matlab 开发环境

4.3 创新点

ALNM 是一个前馈模型，可以使用误差反向传播算法对其进行训练。在训练过程中，保留必要的输入和有用的树突，而剔除不必要和无用的树突。最后，利用神经元剪枝功能，利用 ALNM 预测出精确的树突形态。更有用的是，成熟神经元可以通过逻辑电路进行近似替换，该逻辑电路仅由比较器和逻辑非、与和或门组成，具有强大的运算能力。

5 实验结果分析

从 ALNM 在 Iris 数据集上的表现来看（如图 3），ALNM 的均方误差 (MSE) 在第 100 轮稳定下来，均方误差最终收敛到 0.125 左右。可见，ALNM 具有理想的训练和测试性能，同时具有较快的收敛速度。




图 3: 均方误差

如图 4 所示，未修剪前树突分支的个数是 6 个，修剪后树突分支个数减少到 2 个。并且 ALNM 在 iris 训练集和测试集上的正确率分别为 0.95238 和 0.95556。训练好的 ALNM 可由图 5 的逻辑电路等效代替，逻辑电路在训练集和测试集上取得正确率也分别为 0.95238 和 0.95556。可见，训练后的 ALNM 可以通过逻辑电路进行近似替换。

修剪前树突分支的个数：6

修剪后树突分支的个数：2

ALNM 上训练集的正确率：0.95238

ALNM 上测试集上的正确率：0.95556

逻辑电路上训练集的正确率：0.95238

逻辑电路上测试集的正确率：0.95556

图 4: 实验结果

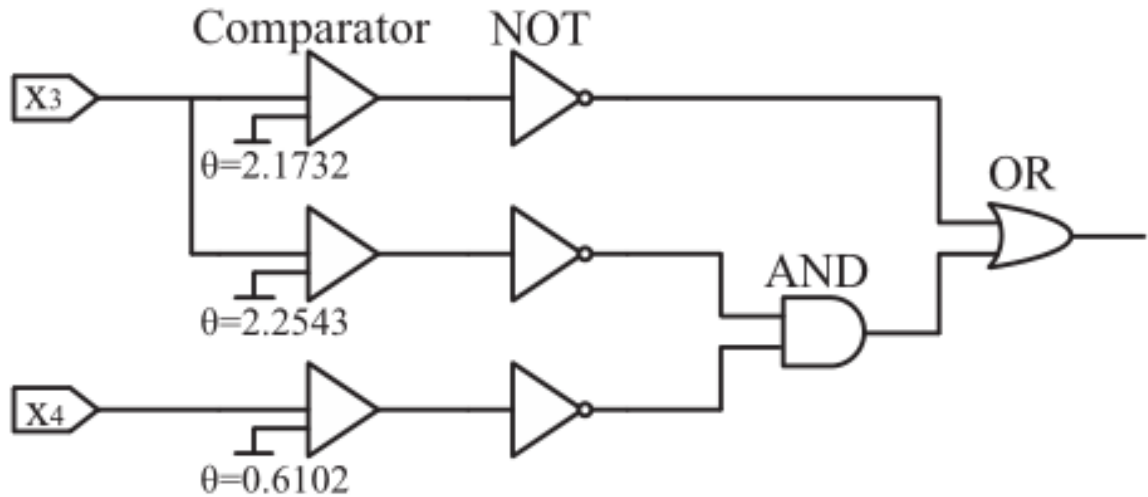


图 5: 逻辑电路

6 总结与展望

本文提出了一种近似逻辑神经元模型 (ALNM)，并与经典的反向传播神经网络进行了比较，在调整权值和阈值数量几乎相等的条件下。在数据集上的实验结果表明，ALNM 算法具有更高的精度和更快的收敛速度。在较大的数据集上，ALNM 比 BP 的优势更加明显。

最初，ALNM 具有比必要的更大的初始化神经拓扑，使得模型对初始条件不太敏感。因此，它将不太可能陷入局部极小值。与标准 BP 网络的全连通性相比，ALNM 通过神经元剪枝功能筛除无用的突触和不必要的树突，大大加快了不同数据集的收敛速度。此外，简化后的拓扑结构使 ALNM 具有良好的泛化能力，不同数据集的测试精度验证了这一点。良好的泛化能力防止了 ALNM 的过拟合，因此 ALNM 是一种处理模式分类问题的有效分类器。

最后，ALNM 演示了一个原始函数，该函数以逻辑 NOT、AND 或 OR 操作的形式提供了每个数据集的逻辑电路，对应于其树状形态，适用于实际的简单硬件实现。未来可以研究如何运用 ALNM 解决一些现实问题，如医疗诊断、图像和文本字符识别，并在硬件上实现它们。